Programación funcional

Julio 2019
Traducido por Leonardo Collado-Torres

@fellgernon
lcolladotor@gmail.com
lcolladotor.github.io

Desarrollado por Charlotte Wickham para rstudio::conf(2019) @cvwickham cwickham@gmail.com cwick.co.nz



Motivación

Copiar y pegar es una fuente rica de errores

```
# Arregla valores faltantes (Leo: Stata usa -99 en vez de NA)
df$a[df$a == -99] <- NA
df$b[df$b == -99] <- NA
df$c[df$c == -99] <- NA
df$d[df$d == -99] <- NA
df$e[df$e == -99] <- NA
df$f[df$f == -99] <- NA
df$g[df$g == -98] <- NA
df h[df = -99] < NA
df$i[df$i == -99] <- NA
df$i[df$j == -99] <- NA
df$k[df$k == -99] <- NA
```

Copiar y pegar es una fuente rica de errores

```
# Arregla valores faltantes
df$a[df$a == -99] <- NA
df$b[df$b == -99] <- NA
df$c[df$c == -99] <- NA
df$d[df$d == -99] <- NA
df$e[df$e == -99] <- NA
df$f[df$f == -99] <- NA
df$g[df$g == -98] <- NA
df h[df = -99] < NA
df$i[df$i == -99] <- NA
df$i[df$j == -99] <- NA
df k df = -99 < -NA
```

Funciones pueden eliminar algunas fuentes de duplicación

```
fix_missing <- function(x) {</pre>
  x[x == -99] \leftarrow NA
  X
df$a <- fix_missing(df$a)</pre>
df$b <- fix_missing(df$b)</pre>
df$c <- fix_missing(df$c)</pre>
df$d <- fix_missing(df$d)</pre>
df$e <- fix_missing(df$e)</pre>
df$f <- fix_missing(df$f)</pre>
df$g <- fix_missing(df$g)</pre>
df$h <- fix_missing(df$h)</pre>
df$h <- fix_missing(df$i)</pre>
```

Funciones pueden eliminar algunas fuentes de duplicación

```
fix_missing <- function(x) {</pre>
  x[x == -99] \leftarrow NA
  X
df$a <- fix_missing(df$a)</pre>
df$b <- fix_missing(df$b)</pre>
df$c <- fix_missing(df$c)</pre>
df$d <- fix_missing(df$d)</pre>
df$e <- fix_missing(df$e)</pre>
df$f <- fix_missing(df$f)</pre>
df$g <- fix_missing(df$g)</pre>
df$h <- fix_missing(df$h)</pre>
df$h <- fix_missing(df$i)</pre>
```

Ciclos de for pueden eliminar otras

```
fix_missing <- function(x) {</pre>
  x\Gamma x == -997 <- NA
  X
for (i in seq_along(df)) {
  df[[i]] <- fix_missing(df[[i]])</pre>
```

Porque los ciclos de for son malos

Un detour con panqués

Porque los ciclos de for son maios GUDÓPIIINOS

Un detour con panqués

El libro de cocina de la panadería hummingbird

1 cup flour

a scant ¾ cup sugar

1 ½ t baking powder

3 Tunsalted butter

½ cup whole milk

1 egg

¼ t pure vanilla extract

Preheat oven to 350°F.

Put the flour, sugar, baking powder, salt, and butter in a freestanding electric mixer with a paddle attachment and beat on slow speed until you get a sandy consistency and everything is combined.

Whisk the milk, egg, and vanilla together in a pitcher, then slowly pour about half into the flour mixture, beat to combine, and turn the mixer up to high speed to get rid of any lumps.

Turn the mixer down to a slower speed and slowly pour in the remaining milk mixture. Continue mixing for a couple of more minutes until the batter is smooth but do not overmix.

Panqués de chocolate

El libro de cocina de la panadería hummingbird

34 cup + 2T flour

2 ½ T cocoa powder

a scant ¾ cup sugar

1 ½ t baking powder

3 Tunsalted butter

½ cup whole milk

1 egg

1/4 t pure vanilla extract

Preheat oven to 350°F.

Put the flour, cocoa, sugar, baking powder, salt, and butter in a freestanding electric mixer with a paddle attachment and beat on slow speed until you get a sandy consistency and everything is combined.

Whisk the milk, egg, and vanilla together in a pitcher, then slowly pour about half into the flour mixture, beat to combine, and turn the mixer up to high speed to get rid of any lumps.

Turn the mixer down to a slower speed and slowly pour in the remaining milk mixture. Continue mixing for a couple of more minutes until the batter is smooth but do not overmix.

Panqués de chocolate

El libro de cocina de la panadería hummingbird

³/₄ cup + 2T flour

2 ½ T cocoa powder

a scant ¾ cup sugar

1½ t baking powder

3 Tunsalted butter

½ cup whole milk

1 egg

½ t pure vanilla extract

Preheat oven to 350°F.

Put the flour, cocoa, sugar, baking powder, salt, and butter in a freestanding electric mixer with a paddle attachment and beat on slow speed until you get a sandy consistency and everything is combined.

Whisk the milk, egg, and vanilla together in a pitcher, then slowly pour about half into the flour mixture, beat to combine, and turn the mixer up to high speed to get rid of any lumps.

Turn the mixer down to a slower speed and slowly pour in the remaining milk mixture. Continue mixing for a couple of more minutes until the batter is smooth but do not overmix.

El libro de cocina de la panadería hummingbird

1 cup flour

a scant ¾ cup sugar

1 ½ t baking powder

3 Tunsalted butter

½ cup whole milk

1 egg

¼ t pure vanilla extract

Preheat oven to 350°F.

Put the flour, sugar, baking powder, salt, and butter in a freestanding electric mixer with a paddle attachment and beat on slow speed until you get a sandy consistency and everything is combined.

Whisk the milk, egg, and vanilla together in a pitcher, then slowly pour about half into the flour mixture, beat to combine, and turn the mixer up to high speed to get rid of any lumps.

Turn the mixer down to a slower speed and slowly pour in the remaining milk mixture. Continue mixing for a couple of more minutes until the batter is smooth but do not overmix.

El libro de cocina de la panadería hummingbird

120g flour

140g sugar

1.5 t baking powder

40g unsalted butter

120ml milk

1 egg

0.25 t pure vanilla extract

Preheat oven to 170°C.

Put the flour, sugar, baking powder, salt, and butter in a freestanding electric mixer with a paddle attachment and beat on slow speed until you get a sandy consistency and everything is combined.

Whisk the milk, egg, and vanilla together in a pitcher, then slowly pour about half into the flour mixture, beat to combine, and turn the mixer up to high speed to get rid of any lumps.

Turn the mixer down to a slower speed and slowly pour in the remaining milk mixture. Continue mixing for a couple of more minutes until the batter is smooth but do not overmix.

1. Convierte las unidades

El libro de cocina de la panadería hummingbird

120g flour

140g sugar

1.5 t baking powder

40g unsalted butter

120ml milk

1 egg

0.25 t pure vanilla extract

Beat flour, sugar, baking powder, salt, and butter until sandy.

Whisk milk, egg, and vanilla. Mix half into flour mixture until smooth (use high speed). Beat in remaining half. Mix until smooth.

Bake 20-25 min at 170°C.

2. Apóyate en el conocimiento del área

120g flour

140g sugar

1.5 t baking powder

40g butter

120ml milk

1 egg

0.25 t vanilla

Beat dry ingredients + butter until sandy.

Whisk together wet ingredients. Mix half into dry until smooth (use high speed). Beat in remaining half. Mix until smooth.

Bake 20-25 min at 170°C.

3. Usa variables

Panqués de chocolate

El libro de cocina de la panadería hummingbird

100g flour

20g cocoa

140g sugar

1.5 t baking powder

40g butter

120ml milk

1 egg

0.25 t vanilla

Beat dry ingredients + butter until sandy.

Whisk together wet ingredients. Mix half into dry until smooth (use high speed). Beat in remaining half. Mix until smooth.

Bake 20-25 min at 170°C.

3. Usa variables

Panqués

Beat dry ingredients + butter until sandy.	120g flour	100g flour
Whisk together wet		20g cocoa
ingredients. Mix half into dry until smooth (use	140g sugar	140g sugar

1 egg

0.25 t vanilla

Vanilla

Bake 20-25 min at 170°C.

smooth.

high speed). Beat in

remaining half. Mix until

140g sugar
1.5t baking powder
40g butter
120ml milk
140g sugar
1.5t baking powder
40g butter
120ml milk

Chocolate

1 egg

0.25 t vanilla

4. Extrae el código en común

¿Qué tienen estos ciclos de for en común?

```
out1 <- vector("double", ncol(mtcars))
for(i in seq_along(mtcars)) {
  out1[[i]] <- mean(mtcars[[i]], na.rm = TRUE)
}

out2 <- vector("double", ncol(mtcars))
for(i in seq_along(mtcars)) {
  out2[[i]] <- median(mtcars[[i]], na.rm = TRUE)
}</pre>
```

Los ciclos de for enfatizan a los objetos

```
out1 <- vector("double", ncol(mtcars))
for(i in seq_along(mtcars)) {
  out1[[i]] <- mean(mtcars[[i]], na.rm = TRUE)
}

out2 <- vector("double", ncol(mtcars))
for(i in seq_along(mtcars)) {
  out2[[i]] <- median(mtcars[[i]], na.rm = TRUE)
}</pre>
```

Y no a las acciones

```
out1 <- vector("double", ncol(mtcars))
for(i in seq_along(mtcars)) {
  out1[[i]] <- mean(mtcars[[i]], na.rm = TRUE)
}

out2 <- vector("double", ncol(mtcars))
for(i in seq_along(mtcars)) {
  out2[[i]] <- median(mtcars[[i]], na.rm = TRUE)
}</pre>
```

La programación funcional enfatiza a las acciones

```
library(purrr)
means <- map_dbl(mtcars, mean)</pre>
```

medians <- map_dbl(mtcars, median)</pre>

Y de regreso...

Ciclos de for pueden eliminar a otros

```
fix_missing <- function(x) {</pre>
  x\Gamma x == -997 <- NA
  X
for (i in seq_along(df)) {
  df[[i]] <- fix_missing(df[[i]])</pre>
```

La PF te permite enfocarte en lo que sucede

```
fix_missing <- function(x) {
   x[x == -99] <- NA
   x
}

df <- modify(df, fix_missing)</pre>
```

Y provee herramientas útiles para la generalización

```
fix_missing <- function(x) {
   x[x == -99] <- NA
   x
}

df <- modify_if(df, is.numeric, fix_missing)</pre>
```

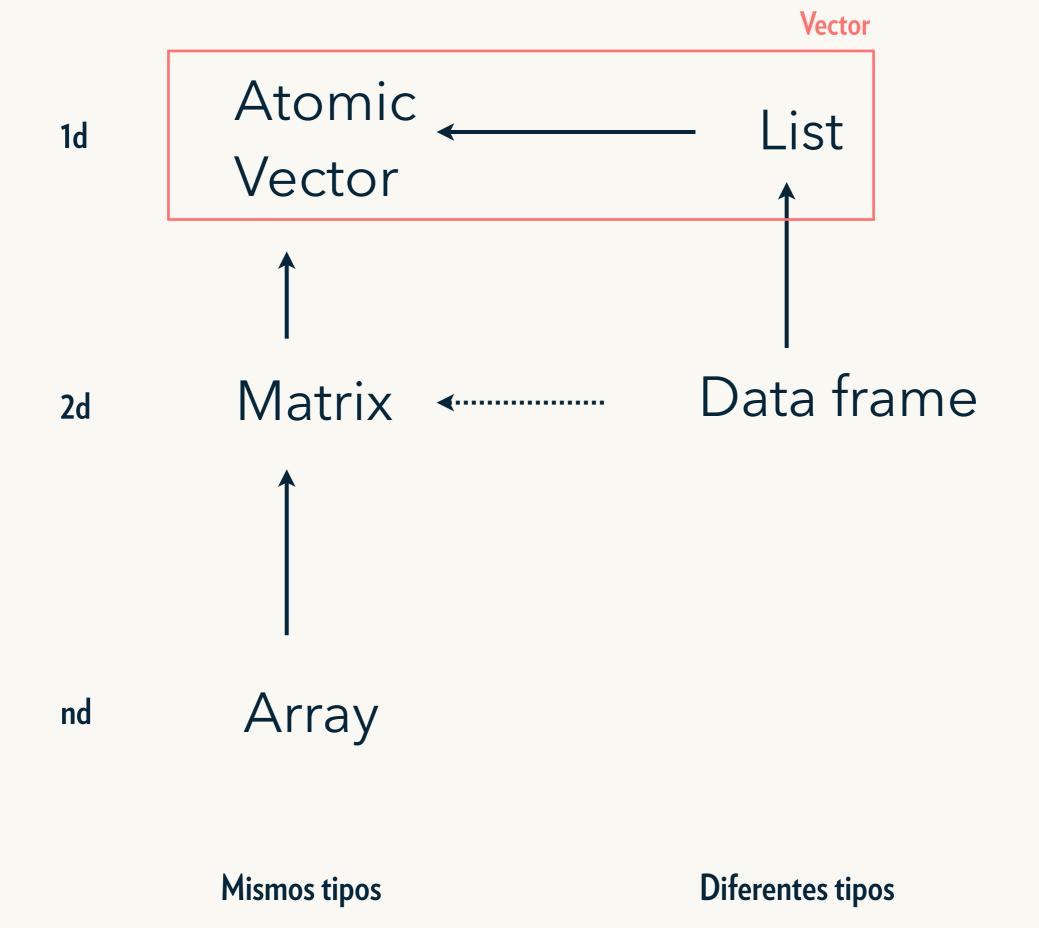
Principio: Resuelve un solo problema

Principio: Amplia con map & amigos

Calentamientos

Tu turno

¿En qué es diferente una list de un atomic vector? ¿En qué es diferente un data frame de una list? ¿Cómo examinarías la estructura de un objeto?



http://adv-r.had.co.nz/Data-structures.html

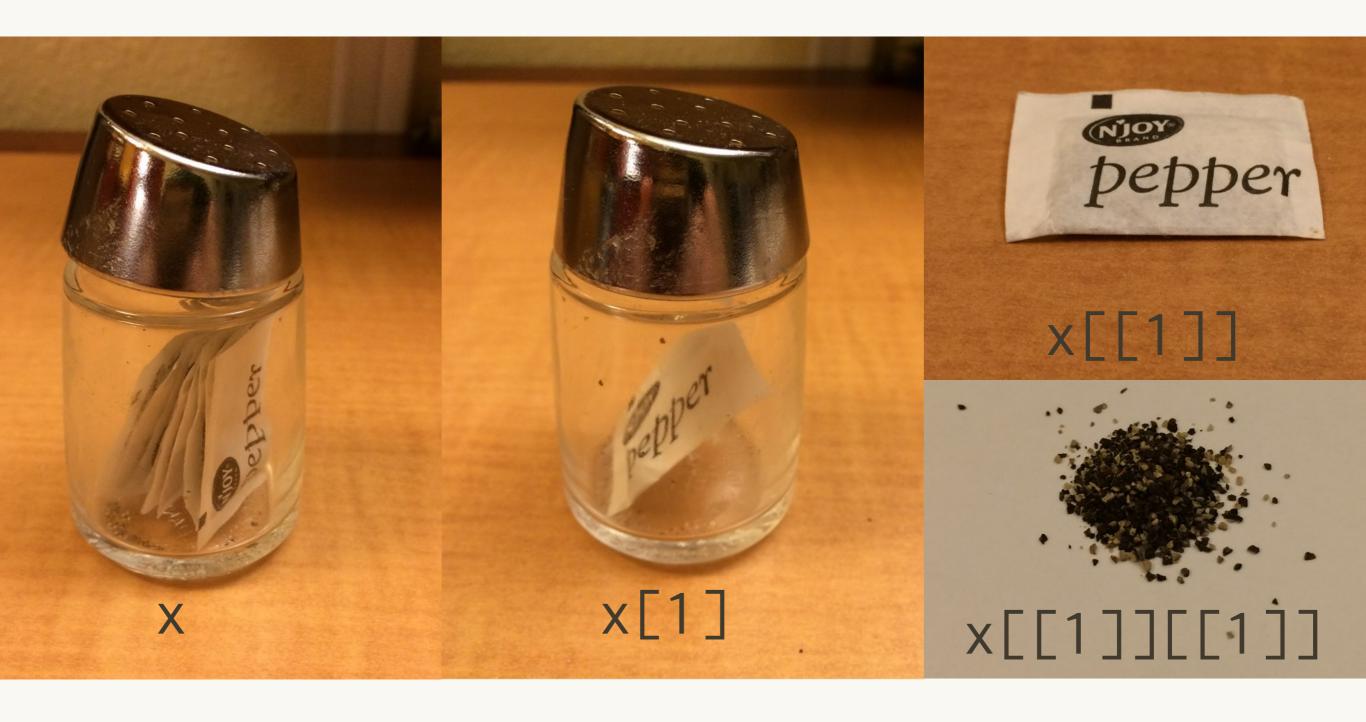
View ()

(Si tienes RStudio $\geq = 1.1$)

Tu turno

¿Cuál es la diferencia entre [y [[?

	Sencillo	Múltiple
Vectors	x[[1]]	x[1:4]
Lists	x[[1]] x\$name	x[1]

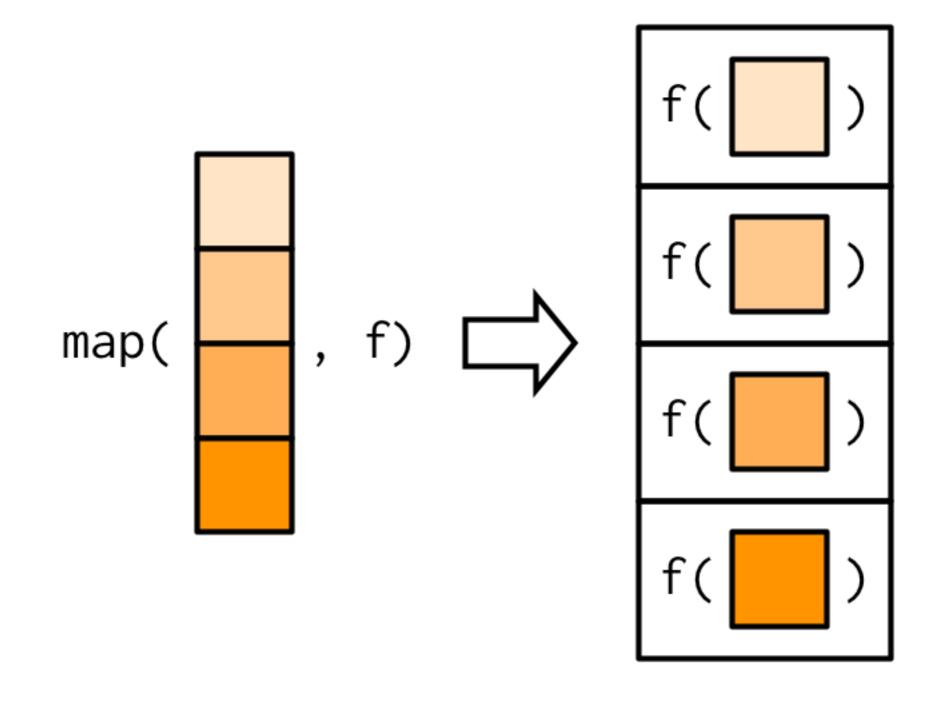


¿Qué hace este código?

```
trans <- list(
  disp = function(x) x * 0.0163871,
  am = function(x) {
    factor(x, labels = c("auto", "manual"))
for(var in names(trans)) {
 mtcars[[var]] <- trans[[var]](mtcars[[var]])</pre>
```

Familia map

map(): para cada elemento, aplica f



Estrategia map

Para una tarea iterativa:

- 1. Resuélvela para un solo .x
- 2. Generaliza la solución con la función map() apropiada
- 3. Simplifica (de ser posible)

Encuentra el primer elemento del texto compuesto

```
strings <- c("a|b", "a|b|c", "d|e", "b|c|d")
# Queremos:
# "a" "a" "d" "b"
# Un objeto intermediario útil
strings_split <- strsplit(strings, "|", fixed = TRUE)</pre>
                                                      [1] "a" "b"
# Para cada elemento de strings_split
# extrae el primer elemento
                                                    # [1] "a" "b" "c"
                                                      [[3]]
                                                      [1] "d" "e"
```

1. Resuelve para un solo .x

```
# Extrae un elemento
.x <- strings_split[[1]]</pre>
      Pronombre especial que map entiende
. X
# [1] "a" "b"
# Obtén el primer elemento
.x[[1]]
# iLo resolvimos!
```

2. Generaliza la solución con map()

```
# Solución para un elemento .xΓ[1]]
```

Conviértela en una receta con ~ y pásala a map

```
map(strings_split, ~ .x[[1]])
```

Para cada elemento de strings_split,

tómalo, y extrae el primer elemento

Estrategia map

Para una tarea iterativa:

- 1. Resuélvela para un solo .x
- 2. Generaliza la solución con la función map() **apropiada**
- 3. Simplifica (de ser posible)

Cada variante siempre resulta en el mismo tipo de objeto

Función	Valor de salida
map_lgl()	Logical vector
<pre>map_int()</pre>	Integer vector
map_dbl()	Double vector
<pre>map_chr()</pre>	Character vector
map()	List
<pre>map_dfc()</pre>	Data frame (by col)
<pre>map_dfr()</pre>	Data frame (by row)

Tipo de objeto garantizado, o un error

```
map(strings_split, ~ .x[[1]]) %>% str()
# List of 4
# $ : chr "a"
# $ : chr "a"
# $ : chr "d"
# $ : chr "b"
map_chr(strings_split, ~ .x[[1]])
# Г1] "a" "a" "d" "b"
map_dbl(strings_split, ~ .x[[1]])
# Error: Can't coerce element 1 from a
character to a double
```

Estrategia map

Para una tarea iterativa:

- 1. Resuélvela para un solo .x
- 2. Generaliza la solución con la función map() apropiada
- 3. Simplifica (de ser posible)

Simplifica la extracción de valores

```
map(z, \sim .x[[1]])
map(z, 1)
map(z, \sim .x[["string"]])
map(z, "string")
map(z, \sim .x[["string"]][[1]] %||% NA)
map(z, list("string", 1), .default = NA))
```

Simplifica el llamado de funciones

```
map(z, ~ f(.x))
map(z, f)

map(z, ~ f(.x, a = 1, b = 2))
map(z, f, a = 1, b = 2)

map(z, ~ f(1, .x))
map(z, f, first_arg = 1)
```

Tu turno

Calcula la media de cada columna en mtcars

Genera 10 valores de la distribución normal al azar usando las siguientes medias: -10, 0, 10, 100

Calcula el número de valores únicos en cada columna de iris

Calcula la media de cada columna en mtcars

```
# Resuelve para un caso
.x <- mtcars[[1]]
mean(.x)
# Generaliza
map_dbl(mtcars, ~ mean(.x))
# Simplifica (opcional)
map_dbl(mtcars, mean)
```

Genera 10 valores de la distribución normales al azar

```
mu <- c(-10, 0, 10, 100)

# Resuelve para un caso
.x <- mu[[1]]
rnorm(10, mean = .x)

# Generaliza
map(mu, ~ rnorm(10, mean = .x))

# Simplifica (opcional)
map(mu, rnorm, n = 10)</pre>
```

Calcula el número de valores únicos en cada columna

```
# Resuelve para un caso
.x <- iris[[1]]
length(unique(.x))
# Generaliza
map_int(iris, ~ length(unique(.x)))
# ¿Simplifica?
nunique <- function(x) length(unique(x))</pre>
map_int(iris, ~ nunique(.x))
map_int(iris, nunique)
```

¿Por qué no R base?

Comparado con purrr, funciones de R base:

```
Tienen nombres inconsistentes (lapply() vs. Map())
Tienen un orden inconsistente de los argumentos (lapply()
vs.mapply())
Requiren funciones (no existe ~, o ayudantes para extraer)
Son tipo-inestable (sapply()) o verbosas (vapply())
No tienen un modo con efectos secundarios (no walk())
No hay mapas pareados (no map2())
No regresan data frames (no _dfc(), _dfr())
```

R base solo provee un conjunto parcial de funciones

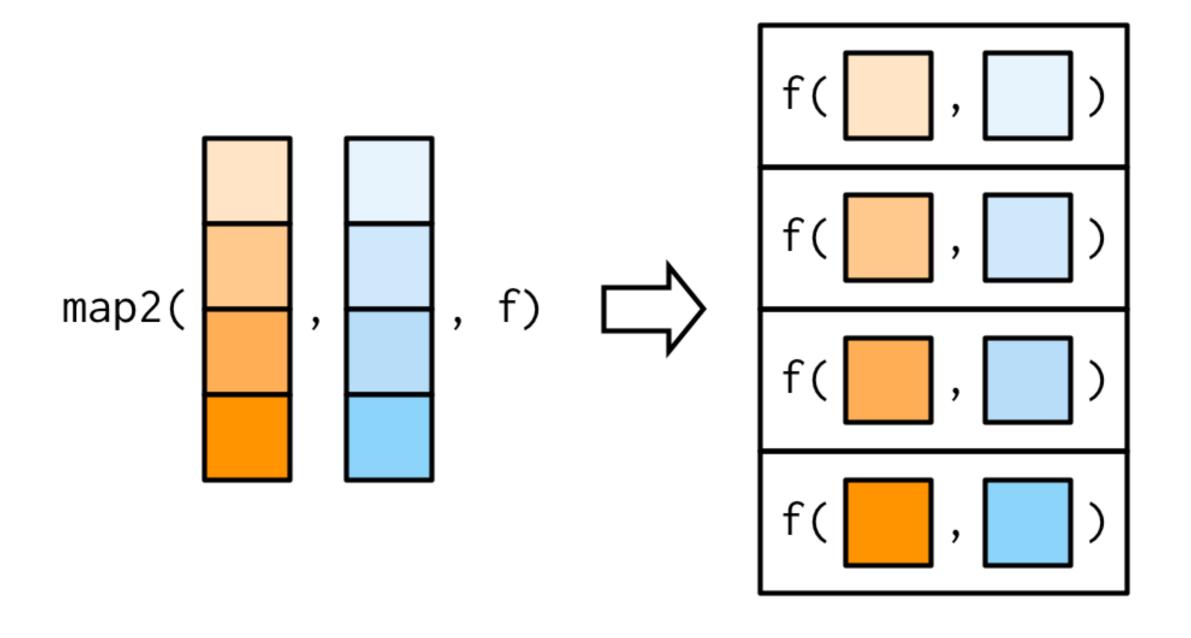
entrada		Valor de salida es escalar	Valor de salida es cualquier cosa	Valor de salida es nada
de valores de el	1	<pre>sapply() / vapply()</pre>	lapply()	
	2			
Número	n	mapply()	Map()	

purrr provee un conjunto completo de funciones

Número de valores de entrada		Valor de salida es escalar	Valor de salida es cualquier cosa	Valor de salida es nada
	1	<pre>map_lgl(), map_int(), map_dbl(), map_chr()</pre>	map()	walk()
	2	<pre>map2_lgl(), map2_int(), map2_dbl(), map2_chr()</pre>	map2()	walk2()
	n	<pre>pmap_lgl(), pmap_int(), pmap_dbl(), pmap_chr()</pre>	pmap()	pwalk()

Mapa pareado

map2(): para cada par de elementos, aplica f



Cuando necesitas iterar sobre dos objetos: map2()

Para una tarea iterativa:

- 1. Resuélvela para un solo .x & .y
- 2. Generaliza la solución con la función map2() apropiada
- 3. Simplifica (de ser posible)

Objetivo: guardar datos en diferentes archivos

```
library(ggplot2)

# una lista de data frames
by_color <- split(diamonds, diamonds$color)

# un vector de archivos
paths <- paste0(names(by_color), ".csv")</pre>
```

1.Resolver para un .x & .y

```
# Resolver para un caso
.x <- by_color[[1]]
.y <- paths[[1]]
write.csv(.x, .y)</pre>
```

2. Generaliza la solución con map2()

```
#
                        write.csv(.x, .y)
map2(by_color, paths, ~ write.csv(.x, .y))
# Usa una función más apropiada
walk2(by_color, paths, ~ write.csv(.x, .y))
# Simplifica (opcional)
walk2(by_color, paths, write.csv)
```

Para limpiar
file.remove(paths)

Principio:

Realiza funciones de valores con map(); realiza funciones con efectos usando walk()

Cambia al proyecto:

[colsum]

Este paquete automáticamente carga purrr

```
devtools::load_all(".")
Loading colsum
Loading required package: purrr
Attaching package: 'purrr'
```

usethis::use_package("purrr", "depends")

Porque antes corrí

A favor

En contra

Fácilmente utiliza funciones de purrr

Afecta el camino de búsqueda global

No es aceptable en CRAN

Tu turno

Escribe la función col_write(df, path) que escribe cada columna de df en un archivo llamado *nombre_columna*.txt, con un valor en cada línea (es decir, usa writeLines()).

Este paquete incluye una unidad de prueba que te permite checar tu trabajo.

Desde R/col_write.R puedes correr devtools::test_file(), para solo correr las pruebas relevantes al archivo.

Una posible solución

Otros tipos de iteración

Valores de entrada	
1	map()
2	map2()
1 + index	imap()
3+	pmap()
functions	invoke_map()

Estabilidad de tipos de objetos

¿Por qué sapply es difícil de utilizar al programar?

```
df <- data.frame(
    a = 1L,
    b = 1.5,
    y = Sys.time(),
    z = ordered(1)
)</pre>
```

Adivina el tipo del objeto del resultado

```
df[1:4] %>% sapply(class) %>% str()
df[1:2] %>% sapply(class) %>% str()
df[3:4] %>% sapply(class) %>% str()
```

Principio:

Minimiza el contexto necesario para predecir el tipo de objeto del resultado

El extremo es una función tipo-estable que siempre regresa el mismo tipo de objeto sin importar el valor de entrada. map()

sapply()

data.frame()

Regresa una list, o muere en el intento Tipo de valor de salida depend del tipo de valor de entrada, longitud y función Factor vs character depende de tu configuración global

La alternativa purrr

```
df <- data.frame(
    a = 1L,
    b = 1.5,
    y = Sys.time(),
    z = ordered(1)
)</pre>
```

Adivina el tipo del objeto del resultado

```
df[1:4] %>% map_chr(class) %>% str()
df[1:2] %>% map_chr(class) %>% str()
df[3:4] %>% map_chr(class) %>% str()
```

Un ejemplo más realista

```
# En R/col_means.R
col_means <- function(df) {
  numeric <- sapply(df, is.numeric)
  numeric_cols <- df[, numeric]

as.data.frame(lapply(numeric_cols, mean))
}</pre>
```

¿Cuál es el problema con col_means?

```
col_means(mtcars)
col_means(mtcars[, 0])
col_means(mtcars[0, ])
col_means(mtcars[, "mpg", drop = F])
df <- data.frame(</pre>
  x = 1:26
  y = letters
col_means(df)
```

Principio:

Piensa en los invariantes

¿Qué debería siempre ser cierto?

¿Cuáles son los invariantes?

```
# ¿Qué es lo que siempre debería ser cierto del resultado?
# * debería ser un data frame
expect_s3_class(out, "data.frame")

# * un renglón
expect_equal(nrow(out), 1)

# * una columna para cada valor numérico del objeto inicial
expect_equal(ncol(out), sum(map_lgl(in, is.numeric))
```

sapply y [no son tipo-estables

Una posible solución

```
col_means <- function(df) {
  numeric <- map_lgl(df, is.numeric)
  numeric_cols <- df[, numeric, drop = FALSE]
  as.data.frame(map(numeric_cols, mean))
}</pre>
```

One possible solution

```
siempre un logical
                                            vector
col_means <- function(df) {</pre>
  numeric <- map_lgl(df, is.numeric)</pre>
  numeric_cols <- df[, numeric, drop = FALSE]</pre>
  as.data.frame(map(numeric_cols, mean)
                                              siempre un
                                               data frame
```

Podemos simplificar aún más con funciones ayudantes

```
col_means <- function(df) {
  numeric_cols <- keep(df, is.numeric)
  map_dfc(numeric_cols, mean)
}</pre>
```

¿Es keep() tipo-estable? Su valor de salida es del mismo tipo que el objeto de entrada Tipo del objeto de salida depende del de entrada keep()

map()

sapply()

data.frame()

Regresa una list, o muere en el intento Tipo de valor de salida depend del tipo de valor de entrada, longitud y función Factor vs character depende de tu configuración global

Es particularmente elegante con el pipe

```
col_means <- function(df) {
   df %>%
     keep(is.numeric) %>%
     map_dfc(mean)
}
```

Invariante fallido

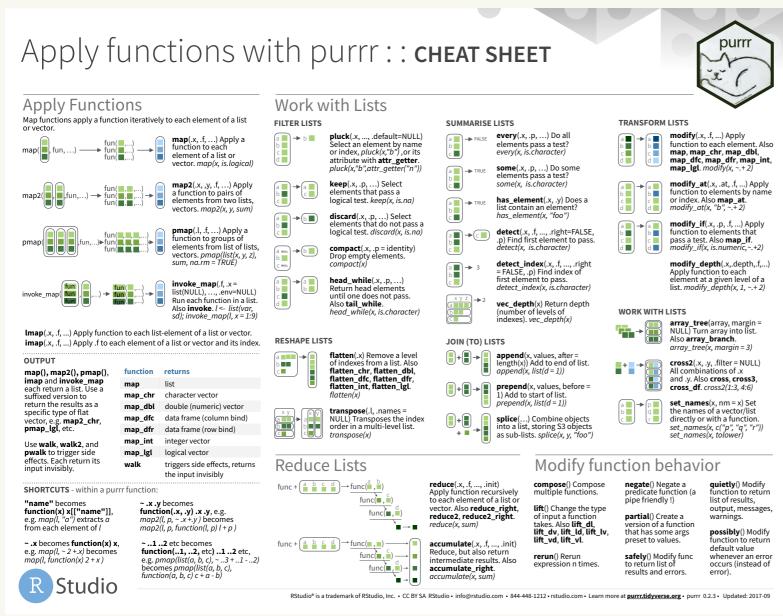
```
col_means(data.frame())
#> data frame with 0 columns and 0 rows
# Debería ser
#> data frame with 0 columns and 1 rows
# ¿Arreglar esto es importante? **
```

Para aprender más

R4DS: https://r4ds.had.co.nz/iteration.html

(en español) https://es.r4ds.hadley.nz/index.html

Advanced R: https://adv-r.hadley.nz/functionals.html



https://github.com/rstudio/cheatsheets/raw/master/purrr.pdf

Adapted from Tidy Tools by Hadley Wickham

This work is licensed as

Creative Commons Attribution-ShareAlike 4.0 International

To view a copy of this license, visit https://creativecommons.org/licenses/by-sa/4.0/