Evaluación "tidy":

Programando con ggplot2 y dplyr

Julio 2019

Traducido por Leonardo Collado-Torres

@fellgernon

Icolladotor@gmail.com

Icolladotor.github.io

Desarrollado por Hadley Wickham para rstudio::conf(2019)

@hadleywickham

Chief Scientist, RStudio



Escribir funciones

```
(df$a - min(df$a)) / (max(df$a) - min(df$a))
(df$b - min(df$b)) / (max(df$b) - min(df$b))
(df$c - min(df$c)) / (max(df$c) - min(df$c))
(df$d - min(df$d)) / (max(df$d) - min(df$c))
```

```
(df$a - min(df$a)) / (max(df$a) - min(df$a))
(df$b - min(df$b)) / (max(df$b) - min(df$b))
(df$c - min(df$c)) / (max(df$c) - min(df$c))
(df$d - min(df$d)) / (max(df$d) - min(df$c))
```

```
(df$a - min(df$a)) / (max(df$a) - min(df$a))
(df$b - min(df$b)) / (max(df$b) - min(df$b))
(df$c - min(df$c)) / (max(df$c) - min(df$c))
(df$d - min(df$d)) / (max(df$d) - min(df$d))
```

Primero, identifica las parques que podrían cambiar

```
(df$a - min(df$a)) / (max(df$a) - min(df$a))
(df$b - min(df$b)) / (max(df$b) - min(df$b))
(df$c - min(df$c)) / (max(df$c) - min(df$c))
(df$d - min(df$d)) / (max(df$d) - min(df$d))
```

Luego dales nombres

Crear el templado de la función

```
rescale01 <- function(x) {
}</pre>
```

Luego copia un ejemplo

```
rescale01 <- function(x) {
  (df$a - min(df$a)) / (max(df$a) - min(df$a))
}</pre>
```

Ahora usa la variable

```
rescale01 <- function(x) {
  (x - min(x)) / (max(x) - min(x))
}</pre>
```

Y tal vez cambia el código un poco

```
rescale01 <- function(x) {
  rng <- range(x)
  (x - rng[1]) / (rng[2] - rng[1]))
}</pre>
```

Ahora agrega más casos

```
rescale01 <- function(x) {
  rng <- range(x, na.rm = TRUE, finite = TRUE)
  (x - rng[1]) / (rng[2] - rng[1]))
}</pre>
```

```
(df$a - min(df$a)) / (max(df$a) - min(df$a))
(df$b - min(df$b)) / (max(df$b) - min(df$b))
(df$c - min(df$c)) / (max(df$c) - min(df$c))
(df$d - min(df$d)) / (max(df$d) - min(df$d))
```

rescale01(df\$a)
rescale01(df\$b)
rescale01(df\$c)

rescale01(df\$d)

¿Por qué crear una función? Porque una función:

- 1. Previene inconsistencias
- 2. Enfatiza que es lo que cambia
- 3. Facilita los cambios
- 4. Puede tener un nombre informativo

Motivación

Tratemos con un poco de código de dplyr

```
df %>% group_by(x1) %>% summarise(mean = mean(y1))
df %>% group_by(x2) %>% summarise(mean = mean(y2))
df %>% group_by(x3) %>% summarise(mean = mean(y3))
df %>% group_by(x4) %>% summarise(mean = mean(y4))
```

Tu turno

Identifica las partes que cambias.

Dales nombres.

Crea una función.

¿Por qué no funciona?

Tratemos con un poco de código de dplyr

```
df %>% group_by(x1) %>% summarise(mean = mean(y1))
df %>% group_by(x2) %>% summarise(mean = mean(y2))
df %>% group_by(x3) %>% summarise(mean = mean(y3))
df %>% group_by(x4) %>% summarise(mean = mean(y4))
```

Primero identifica las partes que cambian

```
df %>% group_by(x1) %>% summarise(mean = mean(y1))
df %>% group_by(x2) %>% summarise(mean = mean(y2))
df %>% group_by(x3) %>% summarise(mean = mean(y3))
df %>% group_by(x4) %>% summarise(mean = mean(y4))
```

Luego dales nombres

```
df group_var summary_var

df %>% group_by(x1) %>% summarise(mean = mean(y1))

df %>% group_by(x2) %>% summarise(mean = mean(y2))

df %>% group_by(x3) %>% summarise(mean = mean(y3))

df %>% group_by(x4) %>% summarise(mean = mean(y4))
```

Ahora crea una función

```
grouped_mean <- function(df, group_var, summary_var) {
   df %>%
     group_by(group_var) %>%
     summarise(mean = mean(summary_var))
}
```

```
No funciona
```

```
grouped_mean <- function(df, group_var, summary_var) {</pre>
 df %>%
  group_by(group_var) %>%
  summarise(mean = mean(summary_var))
grouped_mean(mtcars, cyl, mpg)
#> Error: Column `group_var` is unknown
```

Vocabulario

Necesitamos un poco de vocabulario nuevo

```
Evaluado usando las reglas de
                Rusuales
(x - min(x)) / (max(x) - min(x))
mtcars %>%
 group_by(cyl) %>%
 summarise(mean = mean(mpg))
```

Automáticamente citado (quoted) y evaluado de una forma "no estándar"

Ya estás familiarizado con la siguiente idea

```
df <- data.frame(</pre>
 y = 1,
 var = 2
df$y
var <- "y"
df$var
```

iPredice el resultado!

\$ automáticamente agrega citas al nombre de la variable

```
df <- data.frame(</pre>
 y = 1,
 var = 2
df$y
#> [1] 1
var <- "y"
df$var
#> [1] 2
```

Si quieres referirte a ellas de forma indirecta, tienes que usar [[

```
df <- data.frame(</pre>
 y = 1,
 var = 2
var <- "y"
df[[var]]
#> [1] 1
```

	Citado (quoted)	Evaluado
Directo	df\$ <u>y</u>	???
Indirecto	777	<pre>var <- "y" df[[var]]</pre>

	Citado	Evaluado
Directo	df\$ <u>y</u>	df[["y"]]
Indirecto	???	<pre>var <- "y" df[[var]]</pre>

	Citado	Evaluado
Directo	df\$ <u>y</u>	df[["y"]]
Indirecto		<pre>var <- "y" df[[var]]</pre>

Identifica cuales argumentos son automáticamente citados

```
library(MASS)
mtcars2 <- subset(mtcars, cyl == 4)
with(mtcars2, sum(vs))
sum(mtcars2$am)
```

rm(mtcars2)

¿No puedes determinarlo? Intenta correr el código

```
library(MASS)
#> Works
```

MASS

#> Error: object 'MASS' not found

-> El primer argumento de library() es citado

¿No puedes determinarlo? Intenta correr el código

```
subset(mtcars, cyl == 4)
#> Funciona
cyl == 4
#> Error: object 'cyl' not found
# -> El segundo argumento de subset() es citado
```

Ahora podemos identificar a los argumentos citados

```
library(MASS)
mtcars2 <- subset(mtcars, cyl == 4)
with(mtcars2, sum(vs))
sum(mtcars2$am)
```

rm(mtcars2)

R base tiene 3 formas primarias de "des-citar" ("unquote")

Citado/Directo	Evaluado/Indirecto
df\$ <u>y</u>	x <- "y" df[[x]]
library(<u>MASS</u>)	<pre>x <- "MASS" library(x, character.only = TRUE)</pre>
rm(<u>mtcars</u>)	x <- "mtcars" rm(list = x)



https://www.tidyverse.org/articles/2017/12/workflow-vs-script/

Identifica cuáles argumentos son automáticamente citados

```
library(tidyverse)
mtcars %>% pull(am)
by_cyl <- mtcars %>%
 group_by(cyl) %>%
 summarise(mean = mean(mpg))
ggplot(by_cyl, aes(cyl, mpg)) +
 geom_point()
```

Identifica cuáles argumentos son automáticamente citados

```
library(tidyverse)
mtcars %>% pull(am)
by_cyl <- mtcars %>%
 group_by(cyl) %>%
 summarise(mean = mean(mpq))
ggplot(by_cyl, aes(cyl, mpg)) +
 geom_point()
```

	Citado	Evaluado	Limpio (Tidy)
Directo	df\$y	df[["y"]]	pull(df, <u>y</u>)
Indirecto		<pre>var <- "y" df[[var]]</pre>	???

	Citado	Evaluado	Limpio (Tidy)
Directo	df\$ <u>y</u>	df[["y"]]	pull(df, y)
Indirecto		<pre>var <- "y" df[[var]]</pre>	<pre>var <- quo(y) pull(df, !!var)</pre>

En cualquier lugar del tidyverse usa!! para des-citar (unquote)

```
Pronunciado bang-bang
x_var <- quo(cyl)
y_var <- quo(mpg)</pre>
by_cyl <- mtcars %>%
 group_by(!!x_var) %>%
 summarise(mean = mean(!!y_var))
ggplot(by_cyl, aes(!!x_var, !!y_var)) +
 geom_point()
```

```
x_var <- "cyl"
y_var <- "mpg"
by_cyl <- mtcars %>%
 group_by("cyl") %>%
 summarise(mean = mean("mpg"))
```

Envolviendo funciones que citan

Nuevo: Identifica arguments citados vs evaluados

```
df %>% group_by(x1) %>% summarise(mean = mean(y1))
df %>% group_by(x2) %>% summarise(mean = mean(y2))
df %>% group_by(x3) %>% summarise(mean = mean(y3))
df %>% group_by(x4) %>% summarise(mean = mean(y4))
```

Nuevo: Identifica arguments citados vs evaluados

```
df %>% group_by(x1) %>% summarise(mean = mean(y1))
df %>% group_by(x2) %>% summarise(mean = mean(y2))
df %>% group_by(x3) %>% summarise(mean = mean(y3))
df %>% group_by(x4) %>% summarise(mean = mean(y4))
```

Luego identifica las partes que podrían cambiar

```
df %>% group_by(x1) %>% summarise(mean = mean(y1))
df %>% group_by(x2) %>% summarise(mean = mean(y2))
df %>% group_by(x3) %>% summarise(mean = mean(y3))
df %>% group_by(x4) %>% summarise(mean = mean(y4))
```

Estas partes se convierten en argumentos

Ahora escribe la función templado e identifica los argumentos citados

```
grouped_mean <- function(df, group_var, summary_var) {</pre>
 df %>%
  group_by(group_var) %>%
  summarise(mean = mean(summary_var))
```

Nuevo: Envuelve cada argumento citado en enquo()

```
grouped_mean <- function(df, group_var, summary_var) {</pre>
 group_var <- enquo(group_var)</pre>
 summary_var <- enquo(summary_var)</pre>
 df %>%
  group_by(group_var) %>%
  summarise(mean = mean(summary_var))
```

Nuevo: Y después des-cita (unquote) con!!

```
grouped_mean <- function(df, group_var, summary_var) {</pre>
 group_var <- enquo(group_var)</pre>
 summary_var <- enquo(summary_var)</pre>
 df %>%
   group_by(!!group_var) %>%
   summarise(mean = mean(!!summary_var))
                                       Usa la expresión almacenada en la variable, y
                                           no "summary_var" de forma literal
```

```
grouped_mean(mtcars, cyl, mpg)
grouped_mean <- function(df, group_var, summary_var) {</pre>
 group_var <- enquo(group_var)</pre>
 summary_var <- enquo(summary_var)</pre>
 df %>%
  group_by(!!group_var) %>%
  summarise(mean = mean(!!summary_var))
```

```
grouped_mean(mtcars, cyl, mpg)
grouped_mean <- function(df, group_var, summary_var) {</pre>
 group_var <- quo(cyl)</pre>
 summary_var <- quo(mpg)</pre>
 df %>%
  group_by(!!group_var) %>%
  summarise(mean = mean(!!summary_var))
```

```
grouped_mean(mtcars, cyl, mpg)
grouped_mean <- function(df, group_var, summary_var) {</pre>
 df %>%
  group_by(cyl) %>%
  summarise(mean = mean(mpg))
```

¿Vale la pena?

1:23 PM - 1:43 PM

Friday

Session 5 / programming / Lazy evaluation

The "tidy eval" framework is implemented in the rlang package and is rolling out in packages across the tidyverse and beyond. There is a lively conversation these days, as people come to terms with tidy eval and share their struggles and successes with the community. Why is this such a big deal? For starters, never before have so many people engaged with R's lazy evaluation model and been encouraged and/or required to manipulate it. I'll cover some background fundamentals that provide the rationale for tidy eval and that equip you to get the most from other talks.

Speakers: Jenny Bryan

Nos ahorra mucho código que tendríamos que escribir

```
filter(diamonds, x > 0 & y > 0 & z > 0)
```

```
# vs
diamonds[
  diamonds$x > 0 &
  diamonds$y > 0 &
  diamonds$z > 0,
]
```

Nos ahorra mucho código que tendríamos que escribir

```
filter(diamonds, x > 0 & y > 0 & z > 0)
```

```
# VS
diamonds
 diamonds[["x"]] > 0 &
 diamonds[["y"]] > 0 &
 diamonds[["z"]] > 0,
```

Nos permite traducir el código a otros lenguajes

```
mtcars_db %>%
 filter(<u>cyl > 2</u>) %>%
 select(mpg:hp) %>%
 head(10) %>%
 show_query()
#> SELECT `mpg`, `cyl`, `disp`, `hp`
#> FROM `mtcars`
#> WHERE (`cyl` > 2.0)
#> LIMIT 10
```

Evaluación "Tidy" (limpia) = evaluación no-estandar con principios



Ahora un poco de teoría de juegos

- 1. El código de R es un árbol
- 2. Des-citar construye árboles
- 3. Ambientes ligan nombres a valores

Práctica

Reduce las copias aquí

```
df <- data.frame(</pre>
 g = rep(c("a", "b", "c"), c(3, 2, 2)),
 b = runif(7),
 a = runif(7),
 c = runif(7)
summarise(df, mean = mean(a), sd = sd(a), n = n()
summarise(df, mean = mean(b), sd = sd(b), n = n()
```

summarise(df, mean = mean(c), sd = sd(c), n = n())

```
stat_sum <- function(df, var) {</pre>
 var <- enquo(var)</pre>
 summarise(df,
  mean = mean(!!var),
  sd = sd(!!var),
  n = n()
```

Tu turno

```
# Este código es frecuentemente usado para calcular
# la proporción de una suma agrupada.
# Completa la siguiente función para simplificar
# este patrón útil
mtcars %>% count(cyl) %>% mutate(prop = n / sum(n))
prop <- function(df, x = n) {</pre>
 x <- enquo(x)
```

```
prop <- function(df, x = n) {
  x <- enquo(x)
  df %>% mutate(prop = !!x / sum(!!x, na.rm = TRUE))
}
```

```
prop <- function(df, x = n) {
  x <- enquo(x)
  df %>% mutate(prop = prop.table(!!x))
}
```

```
count_and_prop <- function(df, ..., sort = TRUE) {</pre>
 if ("n" %in% names(df)) {
  # ¿¿¿hacer algo???
 df %>%
  count(..., sort = sort) %>%
  mutate(n = n / sum(n))
```

Crea una función que se pueda re-usar para este patrón

```
counts <- starwars %>%
 group_by(g = homeworld) %>%
 summarise(n = n()) %>%
 head(10) %>%
 mutate(g = reorder(g, n))
counts %>%
 ggplot(aes(g, n)) +
 geom_col() +
 coord_flip() +
 xlab("homeworld")
```

Checa el templado en la siguiente diapositiva

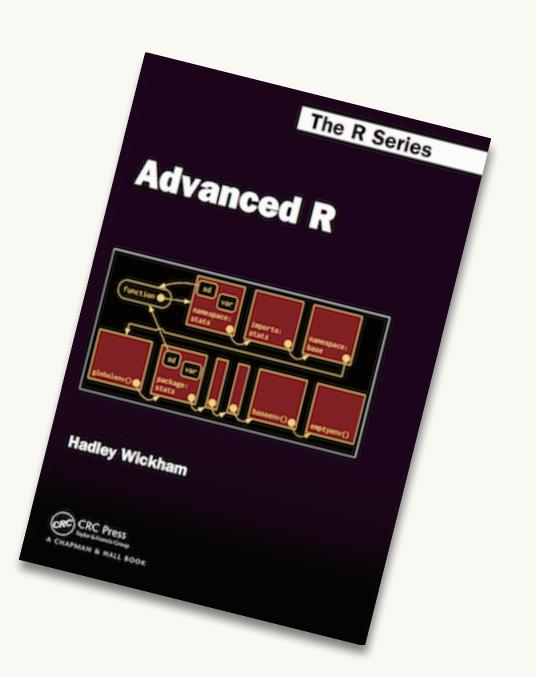
```
top_n <- function(df, x, n = 10) {

# Reto: ¿puedes cambiar el caso base para</pre>
```

manejar mejor los empates?

Aprende más

Teoría



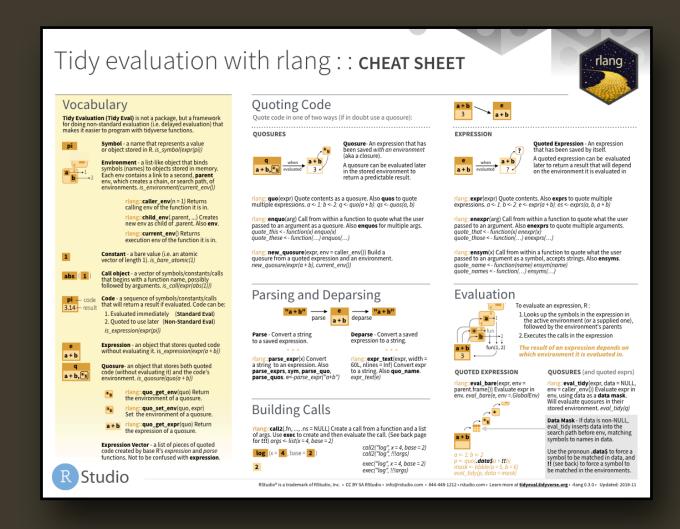
https://adv-r.hadley.nz/expressions.html https://adv-r.hadley.nz/quasiquotation.html https://adv-r.hadley.nz/evaluation.html

https://youtu.be/nERXS3ssntw

Práctica

https://tidyeval.tidyverse.org

(siguen desarrollando esta parte)



Revisemos algunos cambios desde enero del 2019

https://ryo-n7.github.io/2019-07-21-user2019-reflections/



1E ⊟:

本語

VISUALIZATION GALLERY

My useR! 2019 Highlights & Experience: Shiny, R Community, {packages}, and more!

Posted on July 21, 2019

The useR! Conference was held in Toulouse, France and for me this was my second useR! after my first in Brisbane last year. This time around I wanted to write about my experiences and some highlights similar to my post on the RStudio::Conference 2019 & Tidyverse Dev Day earlier this year. This blog post will be divided into 4 sections: Programming, Shiny, {Packages}, and Touring Toulouse.

This work is licensed as

Creative Commons
Attribution-ShareAlike 4.0
International

To view a copy of this license, visit https://creativecommons.org/licenses/by-sa/4.0/